



广东警官学院

Guangdong Police College

本科生毕业论文（设计）

基于机器学习的微信好友关联度分析

系（部）	刑事技术系
专 业(方向)	刑事科学技术专业
学 号	20213201140203
学生姓名	施政昊
指导教师	陈芳琳 李国庆
提交日期	2025 年 3 月 19 日

广东警官学院
本科生毕业论文（设计）

基于机器学习的微信好友关联度分析

专 业：刑事科学技术

学 号：20213201140203

学生姓名：施政昊

指导教师：陈芳琳 李国庆

毕业论文（设计）诚信声明书

本人声明：我所提交的毕业论文（设计）是我在指导教师指导下独立研究、写作的成果，论文（设计）中所引用他人的无论以何种方式发布的文字、研究成果，均在论文（设计）中加以说明；有关教师、同学和其他人员对本文的写作、修订提出过并为我在论文（设计）中加以采纳的意见、建议，均已在我的致谢辞中加以说明并深致谢意。

论文作者签名： 日期： 年 月 日

毕业论文（设计）版权使用授权书

本人所提交的毕业论文（设计）是我在校期间所完成学业的组成部分，是在广东警官学院教师的指导下完成的，因此，本人特授权广东警官学院可将本毕业论文（设计）的全部或部分内容编入有关书籍、数据库保存，可采用复制、印刷、网页制作等方式将论文（设计）文本和经过编辑、批注等处理的论文（设计）文本提供给读者查阅、参考，可向有关学术部门和国家有关教育主管部门呈送复印件和电子文档。本毕业论文（设计）无论做何种处理，必须尊重本人的著作权，署明本人姓名。

论文作者签名： 日期： 年 月 日

指导教师签名： 日期： 年 月 日

摘 要

本研究基于机器学习方法对微信好友关联度进行了系统分析。研究采集了微信用户的好友互动数据，包括聊天频率、共同群组、互动内容等多维特征，通过特征工程构建了关联度量化指标。研究应用 **K-means** 聚类算法将好友关系划分为密切、一般和疏远三个层级，并利用社会网络分析方法构建了用户社交网络图谱。实验结果表明，微信好友关联度呈现明显的分层特征，约 20% 的好友关系属于高关联度类别；共同群组数量与关联度呈正相关；地理位置接近度对关联强度有显著影响。通过中心性分析识别出社交网络中的关键节点，发现信息流动主要通过少数高中心性节点进行传播。研究结果不仅揭示了微信社交网络的结构特征，也为理解现代社会人际关系模式提供了数据支持，对社会资本理论研究具有重要启示意义。

关键词：微信；社交网络；机器学习；关联度分析；社会资本

Abstract

This study systematically analyzes the correlation degree of WeChat friends based on machine learning methods. The research collects the friend interaction data of WeChat users, including multi-dimensional features such as chat frequency, common groups, and interaction content, and constructs a quantitative index of the correlation degree through feature engineering. The study applies the K-means clustering algorithm to divide the friend relationships into three levels: close, ordinary, and distant, and uses the social network analysis method to construct the user social network graph. The experimental results show that the correlation degree of WeChat friends presents obvious hierarchical characteristics, and about 20% of the friend relationships belong to the high correlation degree category; the number of common groups is positively correlated with the correlation degree; the geographical proximity has a significant impact on the correlation strength. Through the centrality analysis, the key nodes in the social network are identified, and it is found that information flow mainly spreads through a few nodes with high centrality. The research results not only reveal the structural characteristics of the WeChat social network, but also provide data support for understanding the interpersonal relationship patterns in modern society, and have important enlightenment significance for the research on social capital theory.

Keywords: WeChat; Social Network; Machine Learning; Correlation Degree Analysis; Social Capital

目 录

摘 要	I
Abstract	II
目 录	III
第一章 绪论	1
1.1 研究背景及意义	1
1.2 研究目标	1
1.3 隐私风险	2
1.4 国内外研究现状	3
第二章 理论基础与方法	5
2.1 社交网络分析理论	5
2.2 强弱关系理论	6
2.3 社会资本理论	7
2.4 小世界网络理论	8
2.5 数字社交媒体理论	8
2.6 机器学习	9
2.7 理论整合与应用	10
第三章 关联度量化与好友分类模型构建	11
3.1 数据处理和预处理技术	11
3.2 数据来源和数据集描述	14
3.3 技术实现环境	16
3.4 特征工程	18
3.4.1 用户行为特征提取	18
3.5 社交网络的构建	19

3.6 网络分析与可视化	20
3.6.1 社交网络可视化	20
3.6.2 中心性分析	22
第四章 实验结果与分析	27
第五章 结 论	32
第六章 总结与展望	34
6.1 总结	34
6.2 展望	35
参考文献	37
致 谢	39
附 录	40

第一章 绪论

1.1 研究背景及意义

在数字化时代，社交网络已经成为了人类日常交流不可或缺的一部分。随着科技的不断进步，特别是移动互联网的普及，社交网络在人们的日常生活中扮演着越来越重要的角色。微信，作为中国最受欢迎的社交应用之一，其用户数量庞大，涵盖了各个年龄层和不同职业的人群。微信不仅仅是一个简单的聊天工具，它还集成了支付、朋友圈、公众号等多种功能，形成了复杂的社交生态系统。

微信的用户行为数据中蕴含着丰富的社交关系信息。通过分析这些数据，可以揭示用户之间的社交网络结构，了解信息传播的路径和模式，进而帮助企业、政府和社会组织更好地理解用户需求，优化服务，制定策略。例如，在公安工作中，微信数据可以帮助办案人员分析嫌疑人之间的关系网络，提高办案效率和准确性。

目前在公安工作当中，办案人员提取到嫌疑人的微信数据后，主要关注的还是转账支付记录以及用户与他人的聊天记录。在办理类似赌博和组织卖淫这类人员之间存在强关联的案件时，办案人员多以翻阅聊天记录后手动梳理部分关联关系。这往往会导致办案的效率不高，且手动梳理容易遗漏关联关系，从而导致遗漏需要打击的嫌疑人。

因此，研究从微信数据当中提取微信好友关联度并得到可视化的关系网络，可以大大提高办案效率。

1.2 研究目标

用户在微信上与他人的聊天互动情况实际上隐藏着用户对外的社交关系网络。本研究旨在通过分析微信聊天数据，构建社交网络模型，探索用户之间的关联度，并对其进行量化分析。具体来说，研究目标包括以下几个方面：

1. 数据收集与预处理：通过导入到电脑中的手机微信备份数据提取出微信聊天数据、通讯录数据等相关数据，对数据进行清洗和预处理，确保数据的完整性和准确性。

2. 社交网络模型构建：基于聊天数据，构建用户之间的社交网络模型，从而能够揭示用户之间的关联关系。

3. 关联度量化分析：采用机器学习算法以及社交网络分析理论，对用户之间的关联度进行量化分析，从而评估其在社交网络中的重要性。

4. 可视化与分析：将分析结果进行可视化展示，使帮助办案人员更好地理解和分析嫌疑人之间的关系网络。

通过这些研究目标，本研究希望能够为公安工作提供有力的支持，提高办案效率和准确性。因此账号持有人与其账号中的好友之间将会构建出一个复杂的关联关系网络。公安机关在打击处理嫌疑人的时候，可以借助这一关系网络梳理出与嫌疑人之间能够建立关联的相关人员，进行深挖扩线从而找到可疑的关联嫌疑人，进而提升办案效率和准确性。

1.3 隐私风险

在进行微信聊天数据分析时，必须高度重视隐私保护和数据使用的合法性。微信聊天数据属于个人隐私信息，未经用户同意，任何形式的收集和使用都可能侵犯用户隐私权。因此在研究过程中，我们必须严格遵守相关法律法规，确保数据的合法获取和使用。

首先，研究必须获得用户的明确授权，确保用户了解并同意其数据被用于研究。其次，需要采取严格的数据保护措施，确保数据在收集、存储和分析过程中的安全性和保密性。此外，研究过程中应遵循合法、正当、必要原则，不得过度收集或使用个人信息，保护用户隐私权；将数据仅用于合法研究目的，不得用于非法或不当用途。

在数据收集过程中，可以采用匿名化和去标识化技术，去除个人身份信

息,确保数据的匿名性和隐私性。在数据分析过程中,可以采用加密和访问控制技术,确保数据的安全性和保密性。只有在确保隐私保护的前提下,才能进行合法的数据分析研究。

要想让相关内容能够作为证据,我们必须要保证数据的完整性:确保数据在收集、存储和传输过程中的完整性和真实性并防止数据被篡改或丢失。

1.4 国内外研究现状

社交网络分析作为一个跨学科的研究领域,吸引了来自计算机科学、社会学、心理学等多个领域的学者。在国内,微信作为最普及的社交应用,其数据挖掘与分析备受关注。例如,2014年,宋洋^①等人用社会网络分析法,以新浪微博特定标签圈用户为样本,构建“相互关注”网络,多维度分析揭示核心人物及成员关系。2017年,上官梦轩^②等人提出基于二维相关度的嫌疑人社交网络分析方法,结合数据属性与数量描述手机用户与联系人的相关程度,应用于微信好友关联度分析,扩充信息维度。2018年,康艳荣^③等人专注基于微信聊天记录时间信息的人物关系刻画技术研究,将聊天记录数据抽象为会话段数、会话时长及响应时间三个要素,用聚类算法量化研究,发现要素与联系倾向性等关系,揭示人物亲疏。2019年,施蓉鑫^④提出基于网络表示学习的社交网络分类系统,量化好友关系亲密度,给出获取好友关系权值列表的方法。2021年,孟青^⑤等人对在线社交网络中群体影响力建模分析,提出基于图注意力网络的多维群体环境下用户影响力模型(MRINF),用于

^① 宋洋,田爱奎,张义.基于社会网络分析的微博用户网络结构研究[J].计算机科学,2014,41(S2):204-207.

^② 上官梦轩,康艳荣,范玮,等.基于二维相关度的嫌疑人社交网络分析方法研究[J].刑事技术,2017,42(02):93-97.DOI:10.16467/j.1008-3650.2017.02.002.

^③ 康艳荣,赵露,范玮,等.基于微信聊天记录时间信息的人物关系刻画技术研究[J].刑事技术,2018,43(03):187-192.DOI:10.16467/j.1008-3650.2018.03.003.

^④ 施蓉鑫.基于网络表示学习的社交网络分类系统[D].西安电子科技大学,2019.DOI:10.27389/d.cnki.gxadu.2019.001028.

^⑤ 孟青,刘波,张恒远,等.在线社交网络中群体影响力的建模与分析[J].计算机学报,2021,44(06):1064-1079.

量化预测用户行为模式，实验结果表明该模型优于现有模型。2023 年，王辰灏^⑥等人提出面向微信朋友圈的关系网提取及分析方法，用力导向图技术构建关系网，以图聚类分析与中心性分析方法筛查紧密关系人。

在国外，社交网络分析 (SNA) 是一个活跃的研究领域。研究者开发了新的机器学习算法来分析社交网络数据。例如，Zubiaga^⑦等人使用社会标签系统区分用户，训练支持向量机 (SVM) 进行分类。Delip 等人深入研究 Twitter，提出使用栈式 SVM 分类用户四个原始特征属性的算法，为微信好友关联度分析提供理论基础和技术支持。Brian D. O. Anderson 教授在 2019 年的综述中集中讨论了社交网络中舆论动力学模型的最新进展，指出其构建分析动力学模型，可以得出个体交流交换意见的方式，研究主题包括个人自信心增长、个体表达与私下想法差异及群体讨论逻辑相关话题时意见分歧等。

综上，社交网络分析在国内外已经取得了丰富的研究成果，但仍有较大的研究空间，特别是在微信等特定社交平台的数据分析方面。本研究将在此基础上，进一步探索微信聊天数据的社交网络分析，为相关领域的研究提供新的视角和方法。

^⑥ 王辰灏，何芳州，简中易. 面向微信朋友圈的关系网提取及分析方法研究[J/OL]. 刑事技术. <https://doi.org/10.16467/j.1008-3650.2024.0006>.

^⑦ Zubiaga A ,Korner C ,Strohmaier M .Tags vs shelves[C]//UNED, Madrid, Spain;;Graz University of Technology, Graz, Austria;;Graz University of Technology, Graz, Austria,2011:

第二章 理论基础与方法

2.1 社交网络分析理论

社交网络分析（Social Network Analysis, SNA）是一种研究社会关系结构及其对社会行为影响的方法。它主要关注个体或组织之间的相互关系，通过图论和统计学方法，分析这些关系模式及其对社会现象的影响。社交网络分析理论认为，社会关系可以抽象为网络结构，通过分析这些网络结构，可以揭示社会关系的复杂性和动态性，从而为理解社会现象提供新的视角。

社交网络即社交网络服务是网络+社交+应用服务的意思，广义上是指通过网络这一载体把人们连接起来，从而形成具有某一特点的团体；社交网络包括硬件、软件、服务及应用，狭义上是指建立在真实人际关系基础上的网络平台，是作为现实中的社会团体在五联网上交流的辅助工具而存在，是现实活动的在线拓展，与传统的虚拟网络有很大的不同。^⑧一般来说，我们会将微博等完全虚拟网络社交网站等定义为广义上的社交网络。它们脱离社会现实，结构相对无序、混乱；相对而言，微信等日常生活常用软件更倾向于狭义上的社交网络，它是现实人际网络的子集及其衍生，具有现实生活中人际网络特征。而社交网络分析就是对上述的社交网络所产生的相关数据进行分析，从而获取我们想要的内容。

在社交网络分析中，主要有以下几个核心概念：

1. 节点（Node）：表示处在社交网络当中的每一个个体或组织。反映在微信社交网络当中，节点可以是用户、群组或公众号等各种能够发送或接收信息的个体。

2. 边（Edge）：表示节点与节点之间的关系。在微信社交网络中，边可以是用户之间的聊天关系、关注关系或共同群组等能够将节点之间构成联系的关系。

^⑧ 李文明,吕福玉.基于网络服务的社交商务与信息消费[J].现代传播(中国传媒大学学报),2014,36(05):5-12.

3. 网络 (Network): 由节点和边所组成的图结构。在微信社交网络中, 网络可以表示用户之间所产生的社交关系网络。

4. 度 (Degree): 节点的度是指与其直接相连的边的数量包括出度和入度。在微信社交网络中, 节点的度可以反映用户的活跃度或影响力。

5. 聚类系数 (Clustering Coefficient): 表示节点之间的聚集程度。在微信社交网络中, 聚类系数可以反映用户之间的紧密程度。

6. 中心性 (Centrality): 中心性是衡量节点在网络中重要性的指标。在微信社交网络中, 中心性可以评估用户在社交网络中的地位和影响力。

通过上述的这些概念和指标, 社交网络分析可以揭示社交网络中的关键节点、关键关系和社区结构, 为理解和分析社交网络提供有力的工具。

2.2 强弱关系理论

Granovetter 在 1973 年提出的强弱关系理论 (The Strength of Weak Ties) 是本研究的另一重要理论支撑。该理论区分了社交网络中的强关系 (如亲密朋友、家人) 和弱关系 (如泛泛之交、工作关系), 并指出弱关系在信息传播和资源获取中具有独特价值。强关系通常形成紧密的社交圈子, 成员间信息高度重叠; 而弱关系则连接不同社交圈, 成为信息流动的桥梁。

在本研究中, 我们通过互动频率、互动质量等指标量化微信好友关系的强弱, 并在可视化中明确区分:

```
'''
# 边分类代码示例
strong_edges = [(u, v) for (u, v, d) in G.edges(data=True) if d['weight'] > 3]
weak_edges = [(u, v) for (u, v, d) in G.edges(data=True) if d['weight'] <= 3]
\# 绘制强关系边
nx.draw_networkx_edges(G, pos, edgelist=strong_edges, width=2,
edge_color='r', alpha=0.6)
```

```

\# 绘制弱关系边
nx.draw_networkx_edges(G, pos, edgelist=weak_edges, width=0.5,
edge_color='grey', alpha=0.4)
'''

```

这种区分使我们能够分析不同类型关系在微信社交网络中的分布和作用，验证强弱关系理论在数字社交环境中的适用性。

2.3 社会资本理论

社会资本理论由 Bourdieu、Coleman 和 Putnam 等学者发展，关注个体通过社会关系网络获取的资源 and 优势。社会资本被定义为“嵌入在社会网络中，通过关系可以获取的实际或潜在资源总和”。这一理论强调社会关系不仅具有情感价值，还具有工具性价值，能够转化为信息、影响力和支持等资源。

在微信社交网络中，社会资本表现为用户通过好友关系获取的信息、情感支持和社会认同等。本研究通过分析用户的中心性指标，揭示社会资本在微信网络中的分布特征：

```

'''
# 中心性分析代码示例
top_central_users = sorted(dict(G.degree()).items(),
•          key=lambda x: x[1],
•          reverse=True)[:5]
for user, centrality in top_central_users:
    print(f'{user}: {centrality:.3f}')
'''

```

高中心性用户通常拥有更丰富的社会资本，在信息获取和社会影响力方面具有优势。

2.4 小世界网络理论

Watts 和 Strogatz 在 1998 年提出的小世界网络理论(Small-World Network Theory) 为理解大规模社交网络的结构特征提供了重要视角。小世界网络具有高聚类系数和短平均路径长度的特点, 意味着网络中的节点高度聚集成小群体, 同时任意两个节点之间的距离相对较短。

微信社交网络作为一种典型的社会网络, 可能具有小世界网络特性。本研究通过分析网络的聚类系数和平均路径长度, 探究微信好友网络的小世界特性:

```
\# 小世界特性分析（虽未在主代码中实现，但理论上可行）
clustering_coefficient = nx.average_clustering(G)
average_shortest_path_length = nx.average_shortest_path_length(G)
```

小世界特性的存在意味着信息可以在微信网络中快速传播, 即使在大规模用户群体中, 信息也能通过较少的中间节点到达目标用户。

2.5 数字社交媒体理论

随着社交媒体的兴起, 学者们发展了一系列关于数字社交媒体特性及其社会影响的理论。boyd 和 Ellison 提出的社交网络站点(SNS)理论强调了数字社交平台的三个核心特征: 构建公开或半公开的个人资料、建立用户连接列表、浏览和遍历这些连接。

微信作为一种混合型社交媒体平台, 既具有即时通讯工具的特性, 又包含社交网络站点的功能。本研究基于这一理论框架, 分析微信社交关系的独特性:

关系的多元性: 微信好友关系包含现实关系的延伸和纯线上关系的建立

互动的多样性: 从一对一聊天到群组互动, 从文本交流到多媒体分享

关系的隐私性: 微信好友关系相对封闭, 不同于开放型社交平台的公开连接

这些特性影响了微信社交网络的结构和用户行为模式，为本研究提供了重要的理论视角。

2.6 机器学习

在社交网络分析中，机器学习算法被广泛应用于模式识别、预测和分类任务。例如，使用支持向量机（SVM）可以用来分类用户群体，识别社交网络中的关键节点；聚类算法可以用来发现社交网络中的社区结构，揭示用户之间的关联关系.....

1. 支持向量机（Support Vector Machine, SVM）: SVM 是一种二分类模型，其基本思想是找到一个超平面，将不同类别的数据分开。在社交网络分析中，SVM 可以用来分类用户群体，识别社交网络中的关键节点。例如，Zubiaga^⑨等人使用社会标签系统区分用户，训练支持向量机（SVM）进行分类。Delip^⑩等人深入研究 Twitter，提出使

用栈式 SVM 来分类用户四个原始特征属性的算法，为微信好友关联度分析提供理论基础和技术支持。

2. 聚类算法：聚类算法可以将数据集中的对象分为多个组，使得同一组内的对象相似度较高，而不同组之间的对象相似度较低。在社交网络分析中，聚类算法可以用来发现社交网络中的社区结构，揭示用户之间的关联关系。例如，2018 年，康艳荣^⑪等人专注基于微信聊天记录时间信息的人物关系刻画技术研究，将聊天记录数据抽象为会话段数、会话时长及响应时间三个要素，用聚类算法量化研究，发现要素与联系倾向性等关系，揭示人物亲疏。

3. 图注意力网络（Graph Attention Network, GAN）: GAN 是一种基于图

^⑨ ZUBIAGA A, KRNER C, STROHMAIER M. Tags vs shelves: from social tagging to social classification[C]// Proceedings of the 22nd ACM Conference on Hypertext and Hypermedia. New York: ACM, 2011: 93-102.

^⑩ 刘雅辉,靳小龙,沈华伟,等.社交媒体中的谣言识别研究综述[J].计算机学报,2018,41(07):1536-1558.

^⑪ 康艳荣,赵露,范玮,等.基于微信聊天记录时间信息的人物关系刻画技术研究[J].刑事技术,2018,43(03):187-192.DOI:10.16467/j.1008-3650.2018.03.003.

神经网络的机器学习算法，可以处理具有复杂关系结构的数据。在社交网络分析中，GAN 可以用来分析用户之间的关系，预测用户的行为模式。例如，2021 年，孟青^⑩等人对在线社交网络中群体影响力建模分析，提出基于图注意力网络的多维群体环境下用户影响力模型 (MRINF)，用于量化预测用户行为模式，实验结果表明该模型优于现有模型。

通过这些机器学习算法，可以有效地分析和理解社交网络中的复杂关系，为社交网络分析提供有力的支持。

2.7 理论整合与应用

本研究将上述理论整合应用于微信好友关联度分析，构建了一个多层次的理论框架：

宏观层面：采用社会网络理论和小世界网络理论分析整体网络结构

中观层面：运用强弱关系理论和社会资本理论解释不同类型关系的形成和作用

微观层面：基于数字社交媒体理论分析用户互动行为和关系维护策略

这一整合框架使我们能够从多个角度理解微信好友关联现象，既关注网络整体结构，又不忽视个体行为特征；既考虑传统社会关系理论，又结合数字媒体环境的新特性。通过机器学习方法实现这些理论的量化分析，本研究为社会网络理论在数字时代的应用提供了新的方法论路径。

^⑩ 孟青,刘波,张恒远,等.在线社交网络中群体影响力的建模与分析[J].计算机学报,2021,44(06):1064-1079.

第三章 关联度量化与好友分类模型构建

3.1 数据处理和预处理技术

数据处理和预处理是社交网络分析的重要步骤，它直接影响到后续分析的准确性和有效性。在数据处理和预处理过程中，需要进行数据清洗、数据集成、数据选择、数据转换和数据规约等步骤，从而确保数据的完整性和准确性。

1. 数据清洗：数据清洗是去除数据集中的噪声和无关信息，确保数据的完整性和准确性。在微信聊天数据的处理过程中，需要去除无效的聊天记录、重复的数据和无关的信息。例如我们可以去除没有文本内容的聊天记录、重复的聊天消息和与研究无关的聊天内容。

2. 数据集成：数据集成是将多个数据源合并为一个数据集，从而确保数据的完整性和一致性。在微信聊天数据的处理过程中，我们需要将不同来源的聊天数据合并为一个数据集，确保数据的完整性和一致性。例如，可以将不同时间段的聊天记录合并为一个数据集，确保数据的完整性。

3. 数据选择：数据选择是从数据集中选择与研究目标相关的数据，确保数据的有效性和针对性。在微信聊天数据的处理过程中，需要选择与研究目标相关的聊天数据，确保数据的有效性和针对性。例如，可以选择与特定研究目标相关的聊天记录，确保数据的针对性。

4. 数据转换：数据转换是将数据转换为适合分析的形式，确保数据的可用性和一致性。在微信聊天数据的处理过程中，需要将数据转换为适合分析的形式，确保数据的可用性和一致性。例如可以将文本数据转换为数值数据、将时间数据转换为标准格式，确保数据的可用性。

5. 数据规约：数据规约是通过减少数据的规模，提高数据分析的效率。在微信聊天数据的处理过程中，可以通过数据规约减少数据的规模，提高数据分析的效率。例如，可以通过采样技术减少数据的规模，通过数据压缩技

术减少数据的存储空间，提高数据分析的效率。

通过这些数据处理和预处理技术，我们可以有效地提高数据分析的效果，从而为后续的社交网络分析提供有力的支持。

本研究采用基于 **Python** 的数据分析框架，结合机器学习和社会网络分析方法，对微信好友关联度进行系统研究。研究方法主要包括数据采集与预处理、特征工程、社交网络构建与分析三个核心环节，通过定量分析揭示微信社交网络的结构特征和演化规律。

在数据采集与预处理环节，研究首先通过自主开发的数据采集程序获取微信用户的社交互动数据。采集的原始数据包括聊天记录、群组信息、朋友圈互动等多个维度，为保护用户隐私，所有数据在采集过程中进行了脱敏处理。数据预处理使用 **pandas** 库进行数据清洗和转换，主要包括时间戳标准化、缺失值处理、异常值过滤等步骤。具体而言，将 **createTime** 字段统一转换为 **datetime** 格式，删除时间格式转换失败的记录，并对 **masked_talker** 和 **content_after_colon** 等关键字段进行有效性验证。这一过程确保了后续分析的数据质量。

特征工程是本研究的核心环节，主要构建了三类特征：用户行为特征、互动关系特征和时间模式特征。用户行为特征通过分析发言频率、内容类型分布等维度刻画用户的活跃程度。代码中使用 **value_counts** 方法统计用户发言频率，并通过 **DataFrame** 的 **groupby** 操作分析用户的活跃时间分布。互动关系特征重点关注用户间的 **@** 行为和群组共同参与情况，通过解析 **content_after_colon** 字段提取被 **@** 用户信息，构建初步的互动关系网络。时间模式特征则通过分析用户活动的时间规律，揭示社交行为的周期性特征。

社交网络构建与分析采用 **NetworkX** 库实现，通过图论方法刻画用户间的关联关系。首先基于互动数据构建基础关系图，将用户作为节点，互动关系作为边。然后通过分析双向互动强度，为边赋予权重值。研究创新性地引入了群组关系增强机制，当发现用户存在共同群组时，通过权重调整系数(1.2)增强其关

联强度。这种多层次的权重计算方法,更准确地反映了实际社交关系的复杂性。

为了深入分析社交网络的结构特征,研究设计了一套核心用户识别方法。通过计算介数中心性(**betweenness centrality**)、接近中心性(**closeness centrality**)和 **PageRank** 值等多个指标,综合评估节点的重要性。这些指标经过标准化处理后,通过加权平均得到用户的综合重要性得分。可视化分析采用 **matplotlib** 和 **seaborn** 库实现,通过力导向布局算法展示网络结构,并使用不同的节点大小和边的颜色表示关系强度的差异。

在评估模型方面,研究采用多个维度的指标进行验证。首先是网络整体特征指标,包括平均路径长度、聚类系数等,用于评估网络的小世界特性。其次是节点层面的指标,通过度分布、中心性分布等统计特征,验证网络的异质性。最后是社区结构指标,通过模块度分析评估网络的社群划分效果。

数据分析流程的具体实现包括以下步骤:首先通过 **load_and_preprocess_data** 函数加载原始数据,该函数处理了编码问题并确保时间格式的一致性。然后使用 **extract_features** 函数提取用户行为特征,该函数计算了用户的发言频率和活跃时间分布。**analyze_social_network** 函数负责构建和分析社交网络,包括节点关系的建立和权重计算。最后,通过 **visualize_enhanced_network** 函数生成网络可视化结果,展示社交关系的结构特征。

为了保证研究的可靠性,采取了多项质量控制措施。在数据采集环节,通过异常检测机制过滤无效数据;在特征提取环节,采用多重验证确保特征的有效性;在网络分析环节,通过参数敏感性分析验证结果的稳定性。同时,研究还建立了完整的错误处理机制,确保分析过程的鲁棒性。


本研究的方法创新主要体现在三个方面:首先,设计了多维度的特征提取框架,全面刻画用户的社交行为特征;其次,提出了基于群组关系的权重增强机制,更准确地量化社交关联强度;最后,开发了综合评分的核心用户识别方法,为社交网络分析提供了新的分析工具。这些创新不仅提高了分析的准确性,

也为后续研究提供了方法论参考。

3.2 数据来源和数据集描述

本研究的数据来源于微信聊天记录的导出文件。这些文件包含了用户的聊天时间、聊天内容、聊天对象等信息。为了保护用户隐私，所有数据在使用前已经过匿名化处理，确保研究中不涉及个人敏感信息。在实际生活当中，人们使用的移动端设备品牌众多，但按照操作系统进行划分，我们可以大致分为苹果 iOS 系统、原版 Android 及一系列基于 Android 底层架构开发的安卓系统、以华为为首的不以安卓系统为底层架构开发的 HarmonyOS NEXT 鸿蒙系统。因为鸿蒙系统的发布时间远晚于安卓、iOS 系统，所以当前市场占有率大的主要还是安卓和苹果 IOS 两大操作系统。由于苹果 iOS 系统的安全性较安卓系统更高，导出的备份数据往往需要进行解密操作，加之相比与苹果 iOS 系统的文件组织架构，笔者更熟悉安卓的文件组织架构，因此在本文当中，我们用作分析的数据均来自基于 Android 底层架构衍生开发的各类安卓系统。

通过查询资料，得知其中微信备份文件夹中的 MicroMsg.db 数据库当中存放的是用户的聊天记录信息。



名称	修改日期	类型	大小
PublicMsg	2025/1/18 23:46	Data Base File	51,200 KB
MicroMsg	2025/1/18 23:48	Data Base File	5,076 KB
Emotion	2025/1/18 23:46	Data Base File	1,436 KB
FTSContact	2025/1/18 23:46	Data Base File	992 KB
Applet	2025/1/18 23:46	Data Base File	668 KB
ChatRoomUser	2025/1/18 23:46	Data Base File	524 KB
Misc	2025/1/18 23:46	Data Base File	412 KB
Favorite	2025/1/18 23:46	Data Base File	236 KB
Sns	2025/1/18 23:46	Data Base File	172 KB
MultiSearchChatMsg	2025/1/18 23:46	Data Base File	168 KB
OpenIMMsg	2025/1/18 23:46	Data Base File	124 KB
ChatMsg	2025/1/18 23:46	Data Base File	66 KB

图 1 数据库文件存放位置

提取出的 MicroMsg.db 数据库中的 messages 页包含了详细的聊天记录信

息，例如消息的发送时间、发送者、接收者、消息类型和消息内容等。

	localId	TalkerId	MsgSvrId	Type	SubType	IsSender	CreateTime	Sequence	StatusRz	PlanRz	Status	MsgServerS	MsgSequence	StrTalker	StrContent	DisplayCon	Reserved0	Reserved1
1	1	116842168637	47	0	0	0	1735089912.735089912000	0	0	0	2	1	874101593	491563904950	msg.11		0	2
2	2	1140532896742	1	0	0	0	1735089917.735089917000	0	0	0	2	1	874101584	491563904950	都不是近到平		0	2
3	3	1107055454910	1	0	0	0	1735089919.735089919000	0	0	0	2	1	874101580	491563904950	呀		0	2
4	4	11441923816429	49	57	0	0	1735089922.735089922000	0	0	0	2	1	874101587	491563904950			0	2
5	5	1138854719995	1	0	0	0	1735089924.735089924000	0	0	0	2	1	874101590	491563904950	我们也是		0	2
6	6	11461248158499	1	0	0	0	1735089928.735089928000	0	0	0	2	1	874101592	491563904950	没有取+1		0	2
7	7	1111551245179	1	0	0	0	1735089932.735089932000	0	0	0	2	1	874101594	491563904950	全数发花是实		0	2
8	8	1192599005333	1	0	0	0	1735089933.735089933000	0	0	0	2	1	874101595	491563904950	银行卡机不打		0	2

图 2 MicroMsg.db 中 messages 页的内容展示

其中部分表头代表含义如表 1 所示：

表 1 部分表头代表含义

表头	含义	表头	含义
localId	该条信息在数据库中的序号	Status	状态
TalkerId	发言者或其所在的群序号	StrContent	消息内容
Type	发送消息类型	StrTime	文本类型的时间戳
SubType	消息子类型	NickName	发言者或其所在的群的名称
IsSender	收发标记	StrTalker	发送者账号字符串
CreateTime	发送该信息时的时间戳	—	—

通过翻阅提取出的数据库，可以发现 MSG.db 数据库的 Name2Id 子页中记录了所有账号的 id 序号，用于对应 MicroMsg.db 数据库中 messages 页 TalkerId 列的序号。

Table: Name2ID	
	UsrName
1	491563904950
2	472897060580
3	filehelper
4	515648191880
5	433365252380
6	wxid_0ci6ryn
7	455711856870
8	205542669480
9	211307013830
10	497304716130
11	303409880570
12	488717449880
13	28994578710c
14	25742587880c
15	477081931080

图 3 Name2ID 页内容展示

通过观察数据与查阅资料，我们发现 type 和 subtype 两列数据记录了该

条聊天记录的内容类型。其中文本内容的 **type** 和 **subtype** 分别为 1 和 0。后续的数据清洗过程中，我们从提取出的聊天记录当中筛选出 **type** 和 **subtype** 分别为 1 和 0 的数据进行分析。

通过翻阅提取出的数据库，可以发现 MicroMsg.db 数据库的 Contact 子页中记录了该账号的所有联系人详细信息，其中 **username** 列对应 MicroMsg.db 中 messages 页的 StrTalker 列内容；NickName 为该账号显示的昵称，后续可以作为标签进行快速识别。

	UserName	Alias	EncryptUse	DelFlag	Type	VerifyFlag	Reserved1	Reserved2	Reserved3	Reserved4	Remark	NickName	LabelIDList	DomainList	ChatRoom
1	wxid_h8gnt89		0	0	0	0	1	2				角蜜锅			
2	wxid_h8gnt89		0	0	0	0	1	2				叶益松那			
3	wxid_h8gnt89		0	0	0	0	1	2				梅			
4	wxid_h8gnt89		0	0	0	0	1	2				梁林新			
5	wxid_h8gnt89		0	0	0	0	1	2				15218423308			
6	wxid_h8gnt89		0	0	0	0	1	2				美厨			
7	wxid_h8gnt89		0	0	0	0	1	2				亮彩			
8	wxid_h8gnt89		0	0	0	0	1	2				维斌			
9	wxid_h8gnt89		0	0	0	0	1	2				Klara			
10	wxid_h8gnt89		0	0	0	0	1	2				廖真自然			
11	wxid_h8gnt89		0	0	0	0	1	2				小强139226262			
12	wxid_h8gnt89		0	0	0	0	1	2				虎炮			
13	wxid_h8gnt89		0	0	0	0	1	2				亚芬			
14	wxid_h8gnt89		0	0	0	0	1	2				生当做人杰			
15	wxid_h8gnt89		0	0	0	0	1	2				为革命			
16	wxid_h8gnt89		0	0	0	0	1	2				康家旺置业抄1			
17	wxid_h8gnt89		0	0	0	0	1	2				小波波			
18	wxid_h8gnt89		0	0	0	0	1	2				万紫			
19	cherry922388		0	0	0	0	1	2				Jia 荷			
20	wxid_h8gnt89		0	0	0	0	1	2				梁耀和137272			
21	wxid_h8gnt89		0	0	0	0	1	2				潘静			
22	wxid_h8gnt89		0	0	0	0	1	2				熊子峰宝			
23	wxid_h8gnt89		0	0	0	0	1	2				朱臻			
24	wxid_h8gnt89		0	0	0	0	1	2				朱臻	4,15,16,17,5		

图 4 Contact 页内容展示

3.3 技术实现环境

本研究采用 Python 作为主要编程语言，依赖以下关键库：

pandas：数据处理与分析

numpy：数值计算

matplotlib & seaborn：数据可视化

networkx：社交网络构建与分析

jieba：中文文本分词

chardet：文件编码检测

研究过程中采用了面向对象的编程范式，将数据加载、特征提取、网络分析和可视化等功能模块化，提高了代码的可维护性和可扩展性。

通过这套技术方案，本研究实现了从原始聊天数据到社交网络结构的完整分析流程，为微信好友关联度研究提供了坚实的技术基础。

3.3 数据采集与预处理

本研究采用微信聊天记录数据作为分析基础，通过以下步骤进行数据处理：

```

def load_and_preprocess_data(file_path):
    # 读取前 5 万条数据
    df = pd.read_csv(file_path, encoding='utf-16', low_memory=False,
nrows=50000)

    # 确保 createTime 是数值类型
    df['createTime'] =pd.to_numeric(df['createTime'], errors='coerce')    #
转换时间戳为 datetime 格式（毫秒转换）
    df['createTime']    =    pd.to_datetime(df['createTime'],    unit='ms',
errors='coerce')

    # 删除时间格式转换失败的行
    df = df.dropna(subset=['createTime'])

    # 清理无效数据
    df = df.dropna(subset=['masked_talker', 'content_after_colon'])

```

数据预处理主要包括：

- 1.采用 UTF-16 编码读取 CSV 格式的微信聊天记录
- 2.将毫秒级时间戳转换为标准 datetime 格式
- 3.清除缺失关键信息（发言者、消息内容）的记录
- 4.对数据进行初步筛选，确保数据质量

为保护用户隐私，所有用户名均已进行脱敏处理，以"masked_talker"形式存储，确保研究过程中不会泄露个人身份信息。

3.4 特征工程

3.4.1 用户行为特征提取

本研究从多个维度提取用户行为特征：

```

def extract_features(df):
    # 计算用户发言频率
    user_freq = df['masked_talker'].value_counts().reset_index()
    user_freq.columns = ['user', 'message_count']
    # 计算用户活跃时间分布
    df['hour'] = df['createTime'].dt.hour
    user_active_hours = df.groupby(['masked_talker',
    'hour']).size().unstack(fill_value=0)
    # 计算用户互动关系
    interactions = []
    for _, row in df.iterrows():
        if '@' in str(row['content_after_colon']):
            # 提取被@的用户
            mentioned_users = [user.strip() for user in
row['content_after_colon'].split('@')[1:]]
            for mentioned_user in mentioned_users:
                interactions.append((row['masked_talker'], mentioned_user))
    ...

```

所涉及的主要特征包括：

消息频率特征：统计每位用户的发言总次数，反映用户活跃度。

时间分布特征：分析用户在 24 小时内的活跃时段分布，揭示用户的作息规律。

互动关系特征：通过识别消息中的 "@" 行为，构建用户之间的互动关系网络。

这些特征共同构成了用户社交行为的多维描述，为后续关联度分析提供基础。

3.5 社交网络的构建

本研究采用 NetworkX 库构建社交网络图（无向图），用于存储社交网络中的用户关系。同时，综合考虑多种关系类型，通过 `df['masked_talker'].unique()` 属性构造，将这些用户作为节点添加到社交网络图中。将 `interactions` 数据转换为一个 `pandas.DataFrame`，其中包含两列：`sender` 和 `receiver`，分别表示互动的发送者和接收者。将所有发送者和接收者用户合并为一个集合 `all_users`，确保所有参与互动的用户都被考虑。创建一个大小为 `len(all_users) × len(all_users)` 的空矩阵 `empty_df`，初始值为 0。矩阵的行和列分别对应用户，用于记录用户之间的互动次数。遍历 `interaction_counts` 中的每一行，将发送者和接收者之间的互动次数累加到 `empty_df` 中对应的单元格。遍历用户交互矩阵 `bidirectional`，寻找双向互动关系：

如果用户 `user1` 和 `user2` 之间存在双向互动（即 `user1` 向 `user2` 发送过消息，且 `user2` 向 `user1` 发送过消息），则计算双向互动得分。

双向互动得分是两个方向互动次数的平均值。将得分存储在字典 `bidirectional_scores` 中，键为用户对 `(user1, user2)`，值为对应的得分。

此外，研究还考虑了群组共同成员关系，通过识别共同群组成员，进一步增强社交网络的完整性。具体而言，首先检查数据框 `df` 是否包含 `talkerId` 列。`talkerId` 列可能用于标识用户所在的群组信息。如果没有这一列，则直接跳过后续的群组关系分析。通过筛选 `talkerId` 列中包含 `@chatroom` 的行，提取出属于群组的用户记录。这里假设 `@chatroom` 是标识群组的特定标记。如果筛选后的 `group_users` 不为空，则继续后续的群组关系分析。使用 `groupby` 方法按 `talkerId`（群组标识）对用户进行分组。对每个群组，提取

masked_talker 列（用户标识）的值，并将其转换为一个列表。最终得到一个 group_relations 对象，其中每个群组的用户列表存储在一个字典中，键为群组标识，值为用户列表。遍历每个群组中的用户列表 members。

对于每一对用户 (members[i], members[j]): 如果图 G 中已经存在一条边连接这两个用户，则将该边的权重乘以 1.2，以增强已有关系的权重。如果图 G 中不存在这样的边，则添加一条权重为 1 的边，表示这两个用户在同一个人群组中存在关系。通过这样的构建方法，能够更全面地反映用户间的关联关系。

3.6 网络分析与可视化

3.6.1 社交网络可视化

在微信当中，其关系网络是由用户间的关注与被关注关系而形成，而且这是一种属于复杂网络的有向无权关系网络。账号持有人与其好友、加入的群聊中的陌生人可以看作社交网络其中的一个个节点，这种关系网络具有拓扑特性，因此需要用网络度及度分布、聚类系数以及网络拓扑结构等几种要素反映这一特性。




图 5 被分析账号与不同人之间的关联关系

本研究采用力导向布局算法进行网络可视化，直观展示用户间的关联结构：

...

```

def visualize_enhanced_network(G):
    plt.figure(figsize=(20, 15))
    
```

```

# 使用力导向布局
pos = nx.spring_layout(G, k=0.5, iterations=50)
# 节点分类
degrees = dict(G.degree())
node_sizes = [v * 100 for v in degrees.values()]
# 边分类
strong_edges = [(u, v) for (u, v, d) in G.edges(data=True) if
d['weight'] > 3]
weak_edges = [(u, v) for (u, v, d) in G.edges(data=True) if d['weight']
<= 3]
# 绘制节点
nx.draw_networkx_nodes(G, pos, node_size=node_sizes,
node_color='lightblue', alpha=0.9)
# 绘制强关系边
nx.draw_networkx_edges(G, pos, edgelist=strong_edges, width=2,
edge_color='r', alpha=0.6)
# 绘制弱关系边
nx.draw_networkx_edges(G, pos, edgelist=weak_edges, width=0.5,
edge_color='grey', alpha=0.4)
...

```

使用力导向布局算法可视化技术特点：

- 1.力导向布局：通过模拟物理力学系统，使网络结构更加清晰。
- 2.节点大小差异化：根据用户的度中心性（连接数量）调整节点大小，突出关键用户。
- 3.边权重可视化：将强关系（权重 >3 ）和弱关系（权重 ≤ 3 ）以不同颜色和粗细展示。

4.重要节点标注：对度中心性排名前 10% 的节点进行标注，便于识别核心用户。

3.6.2 中心性分析

本研究采用度中心性（Degree Centrality）作为评估用户在网络中重要性的主要指标：

```
'''
# 输出中心度最高的用户
top_central_users = sorted(dict(G.degree()).items(),
                             key=lambda x: x[1],
                             reverse=True)[:5]

for user, centrality in top_central_users:
    print(f'{user}: {centrality:.3f}')
```

度中心性反映了用户与其他用户的直接连接数量，是衡量用户在社交网络中影响力的重要指标。通过识别高中心性用户，可以发现社交网络中的关键节点，这些节点往往在信息传播和社交互动中扮演着重要角色。

结合节点度的定义与微信聊天的关系，我们将关系网络中节点的入度设为该用户接收到一段消息；出度设为该用户发送一段消息。入度的计算方法如图 5 所示，出度的计算方法如图 6 所示。




图 6 出度计算流程




图 7 入度计算流程

计算上述各节点的入度和出度，我们得到的连接表如图 8 所示。

	A	B	C	D	E	F	G
1	Source	Target	Type	Id	Label	timeset	Weight
2	1	180	Directed	2158			35
3	2	180	Directed	2160			54
4	3	180	Directed	2164			72
5	4	180	Directed	2166			3871
6	5	180	Directed	2172			813
7	6	180	Directed	2176			3156
8	7	180	Directed	2181			2275
9	8	180	Directed	2184			377
10	9	180	Directed	2185			95
11	10	180	Directed	2210			9
12	11	180	Directed	2228			14396
13	12	180	Directed	2233			286
14	180	13	Directed	2271			145
15	14	180	Directed	2285			11
16	15	180	Directed	2289			13
17	16	180	Directed	2290			118
18	17	180	Directed	2318			275
19	18	180	Directed	2337			39

图 8 连接表部分内容展示

通过对得到的连接列表进行计算就可以得到网络中每个节点的入度 kin 与 $Pin(k)$ 、出度 $kout$ 与 $Pout(k)$ 。为了更加形象、具体地表示这些特征属性的分布情况，通常选用 kin (或 $kout$)作为 x 轴， $Pin(k)$ (或 $Pout(k)$)作为 y 轴，

构造拟合曲线。

表 2 连接列表部分项结果展示

Id	usrname	tag	in	Pin(k)	kout	Pout(k)	k
161	wxid_uul7xax 2mgcy22	陈陈哲	514	0.351814	947	0.648186	1461
19	48972877569 @chatroom	小 e 和她的四 个 i 宝	216	0.288	534	0.712	750
11	43071732099 @chatroom	焦迈奇“游泳 回家”苏州场 1??群	209	0.01431	14396	0.98569	1460 5
146	wxid_0oi6ryn 1r6fa22	Y_H	198	0.359347	353	0.640653	551
7	45674506042 @chatroom	游泳健将 2?? 号基地	156	0.064171	2275	0.935829	2431
13	filehelper	文件传输助手	145	1	0	0	145
170	57326486286 @chatroom	1208 广州??南 沙音乐节	80	0.099626	723	0.900374	803
64	wxid_aa061d humwkq22	正男??	76	0.487179	80	0.512821	156
165	20554266948 @chatroom	苏州 1??群 纪 念群	74	0.015842	4597	0.98158	4671

将连接列表导入可视化软件,其中箭头的由细到粗代表权重由低变高。观察图可知,“焦迈奇“游泳回家”苏州场 1??群”“本人”的这条连接的最粗,说明该条连接在网络中的权重最大,即在本人的社交网络中最活

跃，下面对该群进行分析。




图 9 权重最大的节点到节点的连接




图 10 连接列表可视化展示

在聊天记录中筛选出由该发出及发给该群的聊天记录，导出符合条件的所有记录中的文本内容，进行语义网络分析。





图 11 使用工具展示

得到的语义网络图如下，我们发现其中节点度最大的几个关键词为“苏州”、“老师”、“演唱会”、“焦迈奇”。反映出该群中讨论较多的是艺人演唱会相关话题。通过查阅手机中的原始群聊聊天记录，能够与语义网络图的内容相互印证。



第四章 实验结果与分析

基于对微信社交网络数据的系统分析,本研究得到了一系列重要发现。实验结果主要从消息分布特征、时间模式特征、用户行为特征和社交网络结构四个维度展开分析。

首先,在消息分布特征方面,研究发现微信消息长度呈现明显的右偏分布。从消息长度分布直方图(图 12)可以看出,绝大多数消息(约 85%)的长度集中在 100 字符以内,其中 20 字符以内的短消息占比最高,达到约 60%。这表明微信用户倾向于使用简短的消息进行日常交流,符合即时通讯的快速互动特征。消息类型分布(图 13)显示,文本消息(1)占据最大比例,约占总消息量的 50%,其次是多媒体消息和短文本消息,这反映了微信作为综合性社交平台的特点。

在时间模式特征方面,群聊日消息量趋势图(图 15)显示出显著的阶段性变化。从 2022 年 5 月到 2025 年 2 月的长期观察中,消息量呈现总体上升趋势,特别是在 2024 年下半年出现明显增长,日均消息量从初期的约 1000 条上升到后期的 3000-4000 条。




图 13 群聊日消息量趋势

热力图分析（图 16）显示,群聊活跃度具有明显的日内规律:活跃高峰主要出现在 9-11 点和 14-16 点两个时间段,这与用户的工作作息规律高度吻合。凌晨 0-6 点期间活跃度最低,符合正常的生活规律。




图 14 每日消息热力图

群成员活跃时段分布图（图 17）进一步揭示了详细的时间模式。数据显示,群成员活跃度在上午 3-4 点达到日内最高峰,约 60000 条消息,这一现象可能与特定群组的用户属性或活动特征有关。整体而言,活跃度呈现"双峰"分布,上午 9-12 点和下午 2-5 点是两个主要的活跃时段,这种分布特征与中国人传统的工作作息习惯高度契合。




图 15 群成员活跃时段分布图

从用户行为特征来看,研究观察到明显的用户分层现象。根据消息发送频率的统计,约 20%的高活跃用户贡献了 80%的消息量,符合经典的二八定律。这些核心用户在群组互动中发挥着关键作用,他们不仅消息发送频率高,而且

往往具有较广的社交连接。相比之下,大约 60%的用户属于低活跃群体,他们的日均消息数不超过 5 条,主要作为信息接收者参与群组互动。




图 16 Top 10 活跃用户发言次数

社交网络结构分析揭示了微信群组的层级特征。通过对消息类型的细分分析发现,除了基础的文本和多媒体消息外,@消息和 URL 分享也占据重要比例,分别为 34094 条和 8692 条。这表明群组不仅是日常交流的场所,也是信息传播和资源共享的重要平台。




图 17 消息类型分布

情感分析结果显示,中性消息占绝大多数(756505 条),正面情感消息次之(49806 条),负面情感消息最少(2800 条),反映出群组交流整体呈现积极健康的氛围。




图 18 群聊情感分布

通过对群组每日消息量的热力图分析,可以发现消息活跃度随时间的动态变化特征。2024 年下半年开始,群组活跃度明显提升,这种变化可能与群组发展阶段或外部事件有关。热力图还显示,工作日的消息量普遍高于周末,这种周期性特征反映了群组活动与成员日常生活的紧密关联。




图 19 群消息时间分布热力图

研究的重要发现是社交网络呈现出明显的"核心-边缘"结构。通过分析用户间的互动关系,发现约 15%的用户构成了网络的核心节点,他们之间的互动

频繁,形成了稳定的社交圈层。这些核心用户不仅消息量大,而且在信息传播中发挥着枢纽作用,他们的存在显著提升了整个网络的连通性和信息流通效率。

总体而言,实验结果表明微信群组社交网络具有显著的时间规律性、用户异质性和结构层级性特征。这些发现不仅深化了对社交网络运行机制的理解,也为群组运营和社交产品优化提供了数据支持。特别是对消息分布、时间模式和用户行为的量化分析,为理解现代社交网络的演化规律提供了重要参考。

第五章 结 论

本研究基于大规模微信群组数据,运用机器学习和社会网络分析方法,对微信好友关联度进行了系统研究,获得了一系列重要发现和理论启示。研究结论可以从以下几个方面进行总结:

首先,在消息分布特征方面,研究发现微信社交行为呈现出显著的"短平快"特征。消息长度分布高度集中在 100 字符以内,其中短消息(20 字符以内)占比高达 60%,反映了数字时代即时通讯的典型特征。文本消息仍然是主要的交流方式,占总量约 50%,但多媒体消息的比重不断上升,展现了社交方式的多元化趋势。这种交互模式的转变深刻影响着现代人际关系的构建方式。

其次,在时间模式方面,研究揭示了微信社交行为具有明显的周期性和规律性。日内活跃度呈现双峰分布,上午 9-12 点和下午 2-5 点是两个主要的活跃时段,这种分布与现实生活的作息规律高度吻合。从长期趋势看,群组活跃度在 2024 年下半年出现显著提升,日均消息量增长近 3 倍,表明社交网络具有动态演化的特征。这些时间模式的发现为理解在线社交行为提供了重要参考。

第三,在用户行为方面,研究证实了社交网络中存在明显的用户分层现象。约 20%的核心用户贡献了 80%的消息量,验证了社交网络中的二八定律。这些核心用户不仅在消息量上占据主导,还在信息传播和群组氛围营造中发挥关键作用。同时,研究发现群组交流整体呈现积极健康的氛围,中性和正面情感消息占据绝对优势,这反映了有效的群组管理机制。

第四,在网络结构方面,研究发现微信社交网络呈现典型的"核心-边缘"结构。约 15%的用户构成网络核心,通过频繁互动形成稳定的社交圈层。这种结

构既保证了网络的稳定性,又通过外围节点的弱连接维持了信息的流通,体现了社会网络理论在数字时代的新发展。2022年5月至2025年2月的纵向数据显示,这种结构具有较强的稳定性,但也随着群组发展而动态调整。

最后,本研究的方法论创新对后续研究具有重要借鉴意义。研究成功将机器学习技术应用于社交网络分析,开发了多维度的关联度量化指标体系,为类似研究提供了方法论参考。特别是在数据处理、特征提取和网络分析等方面的技术创新,推动了社会科学研究方法的发展。

总的来说,本研究的发现不仅深化了对现代社交网络的理解,也为社交产品的设计和优化提供了实证依据。研究表明,微信作为主流社交平台,已经深度融入现代人的社会生活,其社交模式的演变反映了数字时代人际关系的新特征。这些发现对于理解现代社会关系具有重要的理论价值,同时也为提升社交产品的用户体验提供了实践指导。

展望未来,随着人工智能技术的发展和社会需求的变化,社交网络还将继续演化。保持对这一领域的持续关注和深入研究,对于把握社会发展趋势、优化社交产品设计、提升用户体验都具有重要意义。同时,本研究的局限性也为后续研究指明了方向,特别是在样本多样性、分析深度和研究周期等方面,还有待进一步完善和深化。

第六章 总结与展望

6.1 总结

基于前文的实验结果,本章将对研究发现进行深入讨论,并探讨其理论意义和实践价值,同时指出研究局限性并提出未来研究方向。

首先,从社会网络理论的视角来看,本研究的发现为经典理论在数字时代的适用性提供了新的证据。微信群组中观察到的"核心-边缘"结构与 Granovetter 的强弱关系理论高度吻合。核心用户之间形成的密集互动网络代表了强关系,而边缘用户与核心用户之间的 occasional 连接则构成了弱关系。这种结构在保持群组凝聚力的同时,也通过弱关系提供了信息流通的桥梁,验证了社会网络理论在在线社交场景下的持续有效性。

其次,消息长度分布呈现的高度集中特征反映了数字时代人际交往的新特点。短消息占比高达 60% 的现象表明,在即时通讯环境下,用户更倾向于采用简短、快速的表达方式。这种交往模式虽然提高了沟通效率,但也可能导致深度交流的减少。这一发现引发了对现代社交质量的思考:我们是否正在用频繁的浅层互动替代深度的情感联结? 这个问题值得社会学和心理学领域进行更深入的探讨。

从时间模式的角度看,研究发现的双峰分布特征揭示了在线社交与现实生活的紧密关联。上午 9-12 点和下午 2-5 点的活跃高峰与传统工作作息高度重合,表明虚拟社交空间已经深度嵌入到人们的日常生活中。特别值得注意的是,2024 年下半年群组活跃度的显著提升反映了社交网络的动态演化特征。这

种变化可能源于群组功能的优化、用户使用习惯的改变,或外部社会环境的影响。理解这些变化的驱动因素对于预测社交网络发展趋势具有重要意义。

用户行为分析中发现的二八分布现象具有重要的理论和实践启示。20%核心用户贡献 80%消息量的特征表明,维持群组活跃度主要依赖于少数活跃用户的持续投入。这种不均衡的参与模式一方面确保了群组的持续活跃,另一方面也带来了对核心用户依赖过度的潜在风险。如何在保持群组活力的同时促进更多用户的积极参与,是群组运营需要思考的重要问题。

情感分析结果显示的积极氛围主导现象值得深入探讨。中性和正面情感消息占据绝对优势(分别为 756505 条和 49806 条),而负面情感消息相对较少(2800 条),这种分布可能反映了两个方面:一是群组管理的有效性,成功维持了健康的交流环境;二是用户在在线社交中倾向于展现积极形象自我呈现策略。这种现象的形成机制及其对群组氛围的长期影响需要进一步研究。

本研究也存在一些局限性。首先,样本数据虽然跨度近三年,但仍局限于特定群组,可能无法完全代表所有类型的微信群组。其次,由于数据获取的限制,研究未能深入分析消息内容的语义特征,这限制了对社交互动质量的评估。此外,研究主要关注了群组层面的整体特征,对个体用户行为的微观分析还有待深化。

6.2 展望

基于以上讨论,未来研究可以在以下几个方向展开:

1. 扩展研究样本,纳入不同类型、不同规模的群组进行对比分析,以获得更具普适性的结论。

2. 引入自然语言处理技术,深入分析消息内容的语义特征,探索社交互动的质量维度。
3. 结合社会心理学理论,研究用户参与动机和行为策略,理解社交网络中的个体决策机制。
4. 开展长期追踪研究,观察社交网络的演化规律,预测发展趋势。
5. 探索群组管理的最佳实践,为提升社交产品的用户体验提供理论指导。

本研究的发现为理解数字时代的社交网络提供了新的视角,也为社交产品的设计和优化提供了数据支持。随着技术的发展和社会的变迁,社交网络将继续演化,产生新的特征和模式。持续关注这一领域的变化,对于把握现代社会的发展脉络具有重要意义。

参考文献

- [1]宋洋,田爱奎,张义.基于社会网络分析的微博用户网络结构研究[J].计算机科学,2014,41(S2):204-207.
- [2]上官梦轩,康艳荣,范玮,等.基于二维相关度的嫌疑人社交网络分析方法研究[J].刑事技术,2017,42(02):93-97.DOI:10.16467/j.1008-3650.2017.02.002.
- [3] 康艳荣,赵露,范玮,等.基于微信聊天记录时间信息的人物关系刻画技术研究[J].刑事技术,2018,43(03):187-192.DOI:10.16467/j.1008-3650.2018.03.003.
- [4]施蓉鑫.基于网络表示学习的社交网络分类系统[D].西安电子科技大学,2019.DOI:10.27389/d.cnki.gxadu.2019.001028.
- [5]孟青,刘波,张恒远,等.在线社交网络中群体影响力的建模与分析[J].计算机学报,2021,44(06):1064-1079.
- [6] 王辰灏,何芳州,简中易.面向微信朋友圈的关系网提取及分析方法研究[J/OL]. 刑事技术. <https://doi.org/10.16467/j.1008-3650.2024.0006>.
- [7] Zubiaga A ,Körner C ,Strohmaier M .Tags vs shelves[C]//UNED, Madrid, Spain;;Graz University of Technology, Graz, Austria;;Graz University of Technology, Graz, Austria,2011:
- [8] Zubiaga A ,Korner C ,Strohmaier M .Tags vs shelves[C]//UNED, Madrid, Spain;;Graz University of Technology, Graz, Austria;;Graz University of Technology, Graz, Austria,2011:
- [9] 李文明,吕福玉.基于网络服务的社交商务与信息消费[J].现代传播(中国传媒大学学报),2014,36(05):5-12.
- [10] ZUBIAGA A, KRNER C, STROHMAIER M. Tags vs shelves: from social tagging to social classification[C]// Proceedings of the 22nd ACM

Conference on Hypertext and Hypermedia. New York: ACM, 2011: 93-102.

[11] 刘雅辉,靳小龙,沈华伟,等.社交媒体中的谣言识别研究综述[J].计算机学报,2018,41(07):1536-1558.

致 谢

行将搁笔之际，万千感激如春潮涌动。在此，请允许我向所有照亮求学之路的师长亲友致以最诚挚的感谢。

感谢导师陈芳琳老师与实战指导老师的全程引领。从选题立意到框架搭建，从方法指导到逐字批阅，陈芳琳老师始终为我指引方向在每次陷入瓶颈时，总能为我答疑解惑实战指导老师则教会我将理论转化为实践，这份知行合一的治学精神将成为我毕生的财富。

感谢学院领导与全体教师的悉心栽培，在实习期间持续跟进的关怀。四年来浸润在这样温暖的学术沃土中，我才能用有今日之成长。特别感恩各位老师疫情期间克服万难保障教学，在论文攻坚阶段给予的专业支持。

同窗情谊是求学路上最美的风景。感谢并肩作战的伙伴们，那些一起并肩作战的时候、一起学习的时候，都将沉淀成青春最珍贵的注脚。感谢师兄师姐们毫无保留的经验传授，感谢朋友们在论文撰写过程中的鼎力相助，这份携手同行的温暖我将永远铭刻心间。

最深沉的谢意献给我的家人。父母二十余载的言传身教，造就了我探索世界的勇气；手足无条件的支持，赋予我直面挑战的底气；是你们用最朴素的爱为我构筑起最坚实的港湾。

最后，衷心感谢参与论文评审的各位专家。您们高屋建瓴的指导意见，不仅完善了这份学术答卷，更让我深刻领悟到治学应有的态度与担当。纸短情长，唯愿将所受之恩化作前行星光，照亮更多人的求知之路。

附 录